

✓ Benchmarky a vyhodnocení modelu

V tomto notebooku navazujeme na předchozí zpracování dat. Načteme si rozdělené sady (Train a Validation), aplikujeme identický preprocessing jako v prvním kroku a stanovíme základní výkonnostní metriky pomocí naivního modelu a logistické regrese.

```
import pandas as pd
import numpy as np
import os
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score, accuracy_score, classification_report, brier_score_loss

# --- 1. PŘÍPRAVA SLOŽEK A STAŽENÍ DAT ---
# Vytvoření složky 'data' pro splnění strukturních požadavků HW2
os.makedirs('data', exist_ok=True)

# ID tvých souborů z Google Drive
file_ids = {
    'train.csv': '1pIaKZQho-MVPGRrcJ6_ECA18TOjdir_h',
    'validation.csv': '1CoJMwK2MeFe_jiMMHnfWB9g0xB2NQPwg',
    'test.csv': '1di85Mr_ZQAVJtP823Cy8y6WyqI_mhRah'
}

print("Stahuji rozdělené datové sady z Google Drive...")
for filename, file_id in file_ids.items():
    !gdown --id {file_id} -O data/{filename}

# --- 2. NAČTENÍ DAT ---
# Načítáme přímo hotové sady, čímž eliminujeme riziko chyby při opakovaném splitu[cite: 5]
df_train = pd.read_csv('data/train.csv')
df_val = pd.read_csv('data/validation.csv')

# Převod na datetime pro následný feature engineering
df_train['launched'] = pd.to_datetime(df_train['launched'])
df_train['deadline'] = pd.to_datetime(df_train['deadline'])
df_val['launched'] = pd.to_datetime(df_val['launched'])
df_val['deadline'] = pd.to_datetime(df_val['deadline'])

print(f"\nData připravena. Train: {len(df_train)} řádků, Val: {len(df_val)} řádků.")
```

```
Stahuji rozdělené datové sady z Google Drive...
/usr/local/lib/python3.12/dist-packages/gdown/__main__.py:139: FutureWarning: Option `--id` was deprecated in version 4.3.1
  warnings.warn(
Downloading...
From: https://drive.google.com/uc?id=1pIaKZQho-MVPGRrcJ6\_ECA18TOjdir\_h
To: /content/data/train.csv
100% 14.4M/14.4M [00:00<00:00, 77.5MB/s]
/usr/local/lib/python3.12/dist-packages/gdown/__main__.py:139: FutureWarning: Option `--id` was deprecated in version 4.3.1
  warnings.warn(
Downloading...
From: https://drive.google.com/uc?id=1CoJMwK2MeFe\_jiMMHnfWB9g0xB2NQPwg
To: /content/data/validation.csv
100% 3.09M/3.09M [00:00<00:00, 187MB/s]
/usr/local/lib/python3.12/dist-packages/gdown/__main__.py:139: FutureWarning: Option `--id` was deprecated in version 4.3.1
  warnings.warn(
Downloading...
From: https://drive.google.com/uc?id=1di85Mr\_ZQAVJtP823Cy8y6WyqI\_mhRah
To: /content/data/test.csv
100% 3.09M/3.09M [00:00<00:00, 207MB/s]

Data připravena. Train: 232168 řádků, Val: 49751 řádků.
```

```
# --- 3. REPRODUKCE PREPROCESSINGU ---
def add_features(data):
    """Odvození délky kampaně (pre-launch feature)[cite: 3]"""
    d = data.copy()
    d['duration_days'] = (d['deadline'] - d['launched']).dt.days
    return d

X_train_raw = add_features(df_train)
X_val_raw = add_features(df_val)

num_cols = ['usd_goal_real', 'duration_days']
cat_cols = ['main_category', 'country']

y_train = X_train_raw['target']
X_train = X_train_raw[num_cols + cat_cols]
```

```

y_val = X_val_raw['target']
X_val = X_val_raw[num_cols + cat_cols]

# Nastavení pipeline (Standardizace + One-Hot Encoding)[cite: 3]
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), num_cols),
        ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), cat_cols)
    ])

# ZLATÉ PRAVIDLO: Fitujeme pouze na trénovací sadě (prevention leakage)
preprocessor.fit(X_train)
X_train_processed = preprocessor.transform(X_train)
X_val_processed = preprocessor.transform(X_val)

# --- 4. BENCHMARKY ---
# A. Naivní baseline (předpovídá vždy neúspěch - většinová třída 0)[cite: 1]
baseline_preds = np.zeros(len(y_val))
baseline_probs = np.zeros(len(y_val))

# B. Jednoduchý ML benchmark (Logistická regrese)[cite: 1, 2]
log_reg = LogisticRegression(max_iter=1000, random_state=42)
log_reg.fit(X_train_processed, y_train)

ml_preds = log_reg.predict(X_val_processed)
ml_probs = log_reg.predict_proba(X_val_processed)[:, 1]

# --- 5. VÝSLEDKY ---
results = pd.DataFrame({
    'Metrika': ['Accuracy', 'F1-Score', 'Brier Score'],
    'Naivní Baseline': [
        accuracy_score(y_val, baseline_preds),
        f1_score(y_val, baseline_preds, zero_division=0),
        brier_score_loss(y_val, baseline_probs)
    ],
    'Logistická Regrese': [
        accuracy_score(y_val, ml_preds),
        f1_score(y_val, ml_preds),
        brier_score_loss(y_val, ml_probs)
    ]
})

print("\n--- POROVNÁNÍ BENCHMARKŮ NA VALIDAČNÍ SADĚ ---")
display(results.round(4))

print("\n--- DETAILNÍ REPORT (Logistická regrese) ---")
print(classification_report(y_val, ml_preds))

```

--- POROVNÁNÍ BENCHMARKŮ NA VALIDAČNÍ SADĚ ---

	Metrika	Naivní Baseline	Logistická Regrese	
0	Accuracy	0.6259	0.6586	
1	F1-Score	0.0000	0.3965	
2	Brier Score	0.3741	0.2140	

--- DETAILNÍ REPORT (Logistická regrese) ---

	precision	recall	f1-score	support
0	0.68	0.87	0.76	31138
1	0.59	0.30	0.40	18613
accuracy			0.66	49751
macro avg	0.63	0.59	0.58	49751
weighted avg	0.64	0.66	0.63	49751

9. Krátké shrnutí

Klíčové metodické body

Na základě zpětné vazby z DÚ1 jsme implementovali postupy pro zajištění maximální robustnosti modelu:

- **Prevention Time Leakage:** Použili jsme striktní chronologický **time-based split** podle data [launched](#).
- **Obrana proti Concept Driftu:** Tímto rozdělením jsme zajistili, že model testujeme na schopnost generalizace v čase, což simuluje reálné nasazení.
- **Konzistence datové pipeline:** V souladu se zadáním pracujeme s dříve uloženými a fixními datovými sadami ([train.csv](#), [validation.csv](#), [test.csv](#)).

Tento postup eliminuje riziko nechtěných změn v rozdělení dat při opakovaném spouštění výpočtů a zaručuje reprodukovatelnost výsledků.

- **Integrita preprocessingu:** Veškeré transformace (scaling, encoding) byly učeny (**fit**) výhradně na trénovací sadě. Tím jsme eliminovali riziko **preprocessing leakage**.
- **Pre-launch focus:** Model pracuje striktně pouze s příznaky (features), které jsou tvůrci projektu známy ještě před ostrým startem kampaně.

Analytické výzvy a insights

Nejobtížnější částí bylo vyladit metriky tak, aby odpovídaly **cost-sensitive** povaze byznys zadání.

Hlavní zjištění: Protože chyba typu **False Positive** (falešný příslib úspěchu) představuje pro tvůrce nejvyšší riziko zbytečné investice, rozšířili jsme evaluaci o **Brier Score**.

- Tato metrika nám pomáhá hodnotit kvalitu **kalibrace pravděpodobností**.
- Cílem je vracet tvůrci spolehlivý odhad šance na úspěch, nikoliv jen striktní binární rozhodnutí.

Další kroky (Next Steps)

V navazující fázi projektu se zaměříme na:

1. **Pokročilé modely:** Experimentování se složitějšími algoritmy jako **Random Forest** nebo **XGBoost**.
 2. **Rozšířený Feature Engineering:** Vytvoření nových časových příznaků, například sezónnost nebo vliv konkrétního měsíce spuštění.
 3. **Thresholding:** Explicitní práce s posouváním rozhodovacího prahu pro aktivní potlačení drahých **False Positive** chyb.
-